

# Complexidade de Algoritmos

## 1. Introdução à Complexidade de Algoritmos

Em ciência da computação, um algoritmo é definido como uma sequência finita de passos bem definidos, tipicamente utilizados para resolver um problema ou realizar uma tarefa computacional específica. A análise da eficiência desses algoritmos torna-se crucial à medida que a escala dos problemas que buscamos resolver aumenta. A complexidade de algoritmos surge como uma métrica fundamental para avaliar essa eficiência, quantificando os recursos computacionais, nomeadamente tempo e espaço de armazenamento, que um algoritmo consome em função do tamanho da entrada <sup>1</sup>. Compreender a complexidade permite aos cientistas da computação e desenvolvedores de software escolher o algoritmo mais adequado para uma determinada tarefa, especialmente quando lidam com grandes volumes de dados. Este relatório tem como objetivo definir, explicar e ilustrar o conceito de complexidade de algoritmos e suas implicações práticas no desenvolvimento de software.

## 2. Definição de Complexidade de Algoritmos

A complexidade de um algoritmo em ciência da computação refere-se à medida da quantidade de recursos computacionais (tempo de computação e espaço de memória) necessários para executar esse algoritmo. Formalmente, ela é expressa como uma função do tamanho da entrada do algoritmo <sup>1</sup>. A análise de complexidade concentra-se em como esses recursos crescem com o aumento do tamanho da entrada, particularmente para entradas muito grandes, um conceito conhecido como comportamento assintótico. Essa análise é vital para prever o desempenho de um algoritmo em diferentes cenários e para comparar a eficiência de diferentes abordagens para resolver o mesmo problema <sup>3</sup>. Embora seja possível analisar o desempenho de um algoritmo no melhor caso, no caso médio e no pior caso, a análise de pior caso é frequentemente a mais relevante, pois fornece um limite superior para o tempo de execução, garantindo assim um certo nível de desempenho em todas as situações.

## 3. Tipos de Complexidade

A análise da complexidade de algoritmos geralmente se divide em duas categorias principais: complexidade de tempo e complexidade de espaço <sup>1</sup>.

### 3.1. Complexidade de Tempo

A complexidade de tempo de um algoritmo define a quantidade de tempo que um algoritmo leva para ser executado como uma função do tamanho da entrada. Ela é tipicamente medida pelo número de operações elementares (como comparações, atribuições, operações aritméticas) que o algoritmo realiza <sup>2</sup>. Ao analisar a complexidade de tempo, o foco está em como o número dessas operações cresce à medida que o tamanho da entrada (geralmente denotado por 'n') aumenta. Essa medida abstrata de tempo de execução é independente da

velocidade específica do processador ou da linguagem de programação utilizada, permitindo uma comparação mais fundamental da eficiência algorítmica.

### **3.2. Complexidade de Espaço**

A complexidade de espaço de um algoritmo, por outro lado, refere-se à quantidade de espaço de memória (ou armazenamento) que o algoritmo utiliza durante sua execução, também como uma função do tamanho da entrada <sup>2</sup>. Isso inclui o espaço ocupado pelos dados de entrada, bem como qualquer espaço adicional utilizado para variáveis auxiliares, estruturas de dados temporárias e o próprio código do algoritmo. Em muitos cenários, especialmente aqueles com recursos de memória limitados, a complexidade de espaço é uma consideração tão importante quanto a complexidade de tempo. É importante notar que, em algumas situações, pode haver uma troca entre complexidade de tempo e complexidade de espaço; por exemplo, um algoritmo pode ser projetado para usar mais memória para reduzir o tempo de execução.

## **4. Notação Big O**

### **4.1. Introdução à Notação Big O**

A notação Big O é uma notação matemática fundamental usada na ciência da computação para descrever o limite superior assintótico da complexidade de tempo ou espaço de um algoritmo <sup>4</sup>. Em termos mais simples, ela fornece uma maneira de expressar como o tempo de execução ou o uso de memória de um algoritmo crescem à medida que o tamanho da entrada se torna muito grande. A beleza da notação Big O reside em sua capacidade de simplificar a análise, concentrando-se no termo dominante que tem o maior impacto no desempenho do algoritmo para grandes entradas, enquanto ignora fatores constantes e termos de ordem inferior <sup>3</sup>.

### **4.2. Significado e Importância da Notação Big O**

A notação Big O é crucial por várias razões. Primeiramente, ela permite que cientistas da computação e desenvolvedores comparem a eficiência de diferentes algoritmos para resolver o mesmo problema de uma maneira padronizada e independente de fatores como hardware específico ou linguagem de programação <sup>3</sup>. Ao focar na taxa de crescimento do tempo de execução ou do espaço de memória em relação ao tamanho da entrada, a notação Big O ajuda a prever como o desempenho de um algoritmo se escalará com conjuntos de dados maiores <sup>4</sup>. Isso é particularmente importante no desenvolvimento de software, onde a capacidade de um aplicativo de lidar eficientemente com grandes quantidades de dados é muitas vezes um fator crítico para o sucesso.

### **4.3. Regras para Determinar a Complexidade Big O**

Existem algumas regras práticas que podem ser seguidas para determinar a complexidade Big

O de um algoritmo a partir de seu código <sup>5</sup>. Operações básicas, como atribuições de variáveis, operações aritméticas e acessos a elementos de array por índice, geralmente levam um tempo constante e são consideradas  $O(1)$ . Em uma sequência de operações, a complexidade geral é determinada pela operação que possui a maior complexidade. Para estruturas de controle como loops, a complexidade é o número de vezes que o loop é executado multiplicado pela complexidade das operações dentro do loop. Em loops aninhados, a complexidade é o produto das complexidades dos loops internos e externos. Finalmente, ao expressar a complexidade Big O, quaisquer fatores constantes e termos de ordem inferior são ignorados, pois se tornam insignificantes à medida que o tamanho da entrada 'n' tende ao infinito <sup>4</sup>. Por exemplo, um algoritmo com uma complexidade de tempo de  $2n^2 + 3n + 5$  é considerado  $O(n^2)$  porque o termo  $n^2$  domina para grandes valores de n.

#### 4.4. Diferentes Classes de Complexidade Big O

As complexidades de algoritmos são frequentemente classificadas em diferentes categorias com base em sua taxa de crescimento em relação ao tamanho da entrada 'n' <sup>3</sup>. Algumas das classes mais comuns incluem:

- **$O(1)$  - Constante:** O tempo de execução (ou espaço) permanece constante, independentemente do tamanho da entrada.
- **$O(\log n)$  - Logarítmica:** O tempo de execução aumenta logaritmicamente com o tamanho da entrada. Esses algoritmos geralmente dividem o problema em partes menores a cada etapa.
- **$O(n)$  - Linear:** O tempo de execução aumenta diretamente proporcionalmente ao tamanho da entrada.
- **$O(n \log n)$  - Linearítmica:** O tempo de execução é um produto de um fator linear e um fator logarítmico. É comum em algoritmos de ordenação eficientes.
- **$O(n^2)$  - Quadrática:** O tempo de execução aumenta com o quadrado do tamanho da entrada, frequentemente devido a loops aninhados.
- **$O(n^3)$  - Cúbica:** O tempo de execução aumenta com o cubo do tamanho da entrada, geralmente envolvendo três loops aninhados.
- **$O(2^n)$  - Exponencial:** O tempo de execução dobra para cada aumento unitário no tamanho da entrada. Esses algoritmos rapidamente se tornam impraticáveis para grandes entradas.
- **$O(n!)$  - Fatorial:** O tempo de execução cresce muito rapidamente com o tamanho da entrada, tipicamente encontrado em algoritmos que exploram todas as permutações possíveis.

#### 5. Exemplos de Algoritmos e Complexidade de Tempo

Para ilustrar as diferentes classes de complexidade de tempo, vamos considerar alguns

exemplos comuns de algoritmos.

### **5.1. $O(1)$ - Complexidade Constante**

Um algoritmo com complexidade de tempo  $O(1)$  executa em um tempo constante, independentemente do tamanho da entrada. Um exemplo clássico é acessar um elemento específico em um array usando seu índice <sup>5</sup>. A operação de acessar o elemento em um índice conhecido leva a mesma quantidade de tempo, não importa quantos elementos o array contenha. Outro exemplo é trocar os valores de duas variáveis.

### **5.2. $O(\log n)$ - Complexidade Logarítmica**

Algoritmos com complexidade de tempo  $O(\log n)$  geralmente dividem o problema em partes menores a cada etapa. Um exemplo proeminente é o algoritmo de busca binária <sup>5</sup>. Em uma busca binária, para encontrar um elemento em um array ordenado, o algoritmo compara o elemento de destino com o elemento do meio. Se não forem iguais, metade do array é eliminada, e a busca continua na metade restante. Esse processo é repetido até que o elemento seja encontrado ou o subarray esteja vazio. O número de etapas necessárias é logarítmico em relação ao tamanho do array.

### **5.3. $O(n)$ - Complexidade Linear**

Um algoritmo com complexidade de tempo  $O(n)$  executa um número de operações diretamente proporcional ao tamanho da entrada. Um exemplo típico é procurar o menor item em um array não ordenado <sup>9</sup>. Para fazer isso, o algoritmo precisa examinar cada elemento do array uma vez. Da mesma forma, um procedimento que soma todos os elementos em uma lista também requer um tempo proporcional ao número de elementos na lista <sup>9</sup>.

### **5.4. $O(n \log n)$ - Complexidade Linearítmica**

Algoritmos com complexidade de tempo  $O(n \log n)$  são frequentemente encontrados em algoritmos de ordenação eficientes. Exemplos incluem Merge Sort, Heap Sort e Quicksort (no caso médio) <sup>4</sup>. O Merge Sort, por exemplo, divide recursivamente a lista em sublistas até que cada sublista contenha apenas um elemento, e então mescla repetidamente as sublistas para produzir uma lista ordenada. A fase de divisão leva tempo logarítmico, e a fase de mesclagem leva tempo linear para cada nível da recursão, resultando em uma complexidade total de  $O(n \log n)$ .

### **5.5. $O(n^2)$ - Complexidade Quadrática**

Algoritmos com complexidade de tempo  $O(n^2)$  geralmente envolvem loops aninhados que iteram sobre os dados. Exemplos comuns incluem Bubble Sort e Insertion Sort <sup>5</sup>. No Bubble Sort, para cada elemento do array, o algoritmo compara e potencialmente troca elementos

adjacentes várias vezes para "borbulhar" o maior elemento para o final. Esse processo é repetido para cada elemento, resultando em um tempo de execução proporcional ao quadrado do número de elementos.

## **6. Exemplos de Algoritmos e Complexidade de Espaço**

A complexidade de espaço, como mencionado anteriormente, refere-se à quantidade de memória que um algoritmo utiliza. Aqui estão alguns exemplos com diferentes complexidades de espaço.

### **6.1. $O(1)$ - Complexidade de Espaço Constante**

Um algoritmo tem complexidade de espaço  $O(1)$  se a quantidade de memória extra que ele usa permanece constante, independentemente do tamanho da entrada. Um exemplo é um algoritmo que apenas usa algumas variáveis para armazenar valores temporários durante a computação. Algoritmos de ordenação "in-place", como o Insertion Sort (considerando apenas o espaço auxiliar), geralmente têm complexidade de espaço  $O(1)$ , pois eles ordenam os elementos dentro do próprio array com uma quantidade mínima de espaço extra.

### **6.2. $O(n)$ - Complexidade de Espaço Linear**

Um algoritmo tem complexidade de espaço  $O(n)$  se a quantidade de memória extra que ele usa é diretamente proporcional ao tamanho da entrada. Um exemplo é a criação de uma cópia de um array de entrada. Se o array de entrada tiver 'n' elementos, a cópia também terá 'n' elementos, resultando em uma complexidade de espaço  $O(n)$ . Outro exemplo é o Merge Sort, que, em sua implementação típica, requer um espaço auxiliar de tamanho 'n' para realizar a operação de mesclagem <sup>10</sup>.

### **6.3. $O(n^2)$ - Complexidade de Espaço Quadrática**

Um algoritmo tem complexidade de espaço  $O(n^2)$  se a quantidade de memória extra que ele usa é proporcional ao quadrado do tamanho da entrada. Isso pode ocorrer, por exemplo, ao processar ou armazenar dados em uma matriz bidimensional onde as dimensões são proporcionais ao tamanho da entrada. Um exemplo poderia ser a representação de uma matriz de adjacência para um grafo com 'n' nós, onde a matriz teria dimensões  $n \times n$ .

## **7. Comparação de Complexidade de Algoritmos para o Mesmo Problema**

A escolha do algoritmo certo para resolver um problema pode ter um impacto significativo na eficiência, especialmente para grandes conjuntos de dados. É comum que diferentes algoritmos que resolvem o mesmo problema apresentem diferentes complexidades de tempo e espaço <sup>3</sup>.

Considere o problema de pesquisar um elemento em um array. Uma abordagem é a pesquisa linear, onde cada elemento do array é verificado sequencialmente até que o elemento desejado seja encontrado ou o final do array seja alcançado. No pior caso, a pesquisa linear tem uma complexidade de tempo de  $O(n)$ , pois pode ser necessário examinar todos os 'n' elementos. Se o array estiver ordenado, uma abordagem mais eficiente é a busca binária, que, como discutido anteriormente, tem uma complexidade de tempo de  $O(\log n)$ . Para grandes arrays, a diferença entre  $O(n)$  e  $O(\log n)$  pode ser substancial.

Outro exemplo é o problema de ordenar um array. Vários algoritmos de ordenação existem, cada um com sua própria complexidade. Bubble Sort, Insertion Sort e Selection Sort têm uma complexidade de tempo de  $O(n^2)$ , o que os torna ineficientes para grandes arrays. Algoritmos como Merge Sort e Heap Sort oferecem uma complexidade de tempo melhor de  $O(n \log n)$ , tornando-os mais adequados para ordenar grandes conjuntos de dados <sup>9</sup>. A escolha entre esses algoritmos pode depender de outros fatores, como a complexidade de espaço e a estabilidade da ordenação.

A tabela abaixo resume a complexidade de tempo de alguns algoritmos comuns para ordenação e busca:

Algoritmo	Complexidade de Tempo (Melhor Caso)	Complexidade de Tempo (Caso Médio)	Complexidade de Tempo (Pior Caso)
Bubble Sort	$O(n)$	$O(n^2)$	$O(n^2)$
Insertion Sort	$O(n)$	$O(n^2)$	$O(n^2)$
Selection Sort	$O(n^2)$	$O(n^2)$	$O(n^2)$
Merge Sort	$O(n \log n)$	$O(n \log n)$	$O(n \log n)$
Quick Sort	$O(n \log n)$	$O(n \log n)$	$O(n^2)$
Heap Sort	$O(n \log n)$	$O(n \log n)$	$O(n \log n)$
Linear Search	$O(1)$	$O(n)$	$O(n)$
Binary Search	$O(1)$	$O(\log n)$	$O(\log n)$

Essa comparação demonstra claramente como a escolha do algoritmo pode afetar drasticamente o desempenho, especialmente à medida que o tamanho da entrada aumenta. Para entradas pequenas, um algoritmo com maior complexidade, mas com constantes menores, pode ter um desempenho melhor, mas para entradas suficientemente grandes, o algoritmo com a menor taxa de crescimento de complexidade será mais eficiente <sup>3</sup>.

## 8. Impacto das Estruturas de Dados na Complexidade de um Algoritmo

A maneira como os dados são organizados e armazenados, ou seja, a estrutura de dados escolhida, tem um impacto profundo na complexidade dos algoritmos que operam sobre esses dados <sup>10</sup>. Diferentes estruturas de dados são otimizadas para diferentes tipos de operações, e a escolha inadequada pode levar a ineficiências significativas.

Por exemplo, em um array (ou vetor), acessar um elemento em uma posição específica leva um tempo constante,  $O(1)$ , pois os elementos são armazenados em posições contíguas na memória e podem ser acessados diretamente pelo índice <sup>10</sup>. No entanto, inserir ou remover um elemento no meio de um array pode ter uma complexidade linear,  $O(n)$ , pois pode ser necessário deslocar todos os elementos subsequentes para abrir ou fechar espaço.

Em contraste, uma lista ligada permite inserções e remoções em qualquer posição com complexidade constante,  $O(1)$ , desde que se tenha um ponteiro para o nó anterior. No entanto, acessar um elemento em uma posição específica em uma lista ligada requer percorrer a lista desde o início, resultando em uma complexidade linear,  $O(n)$  <sup>10</sup>.

Estruturas de dados mais complexas, como árvores de busca binária balanceadas, são projetadas para otimizar operações de busca, inserção e remoção, geralmente com uma complexidade logarítmica,  $O(\log n)$ . Já um dicionário (ou hashmap) oferece, em média, complexidade constante,  $O(1)$ , para operações de busca, inserção e remoção, através do uso de chaves e funções de hash <sup>10</sup>. No entanto, no pior caso (por exemplo, muitas colisões em um hashmap), essas operações podem degradar para uma complexidade linear,  $O(n)$ .

A tabela abaixo resume a complexidade de tempo de operações comuns em diferentes estruturas de dados:

Estrutura de Dados	Busca	Inserção	Remoção
Array	$O(n)$	$O(n)$	$O(n)$
Lista Ligada	$O(n)$	$O(1)$	$O(1)$

Hash Table (Caso Médio)	$O(1)$	$O(1)$	$O(1)$
Hash Table (Pior Caso)	$O(n)$	$O(n)$	$O(n)$
Árvore de Busca Binária Balanceada	$O(\log n)$	$O(\log n)$	$O(\log n)$

Essa tabela ilustra como a escolha da estrutura de dados pode influenciar a eficiência das operações realizadas sobre os dados, afetando diretamente a complexidade de tempo dos algoritmos que as utilizam. Portanto, a seleção da estrutura de dados apropriada é uma decisão crucial no projeto de algoritmos eficientes.

## 9. Complexidade de Algoritmos e Escalabilidade de Software

A complexidade dos algoritmos utilizados em um software tem uma relação direta e significativa com a sua capacidade de escalar, ou seja, de lidar com o aumento da carga de trabalho ou do volume de dados <sup>6</sup>. Um software é considerado escalável se puder manter um desempenho aceitável mesmo quando o número de usuários ou a quantidade de dados que ele processa cresce significativamente.

Algoritmos com alta complexidade, como  $O(n^2)$  ou  $O(2^n)$ , podem funcionar bem para pequenas quantidades de dados, mas tendem a se tornar extremamente lentos e ineficientes à medida que o tamanho da entrada aumenta <sup>6</sup>. Isso ocorre porque o tempo de execução desses algoritmos cresce exponencialmente ou quadraticamente com o tamanho da entrada. Consequentemente, um software que depende fortemente de algoritmos com alta complexidade pode ter dificuldades em escalar para atender a um grande número de usuários ou a um grande volume de dados, pois o tempo de resposta pode se tornar inaceitável.

Por outro lado, algoritmos com baixa complexidade, como  $O(\log n)$  ou  $O(n)$ , geralmente permitem uma melhor escalabilidade <sup>6</sup>. O tempo de execução desses algoritmos cresce de forma mais lenta com o aumento da entrada, o que significa que o software pode lidar com um número maior de usuários e dados de forma mais eficiente. Por exemplo, um algoritmo com complexidade  $O(\log n)$  terá seu tempo de execução aumentado apenas ligeiramente mesmo que o tamanho da entrada seja multiplicado por um fator significativo.

Portanto, ao projetar um software que precisa ser escalável, é fundamental escolher algoritmos eficientes e com baixa complexidade para as tarefas críticas <sup>6</sup>. A otimização de algoritmos existentes também pode ser uma estratégia importante para melhorar a escalabilidade de um sistema. Além disso, a escolha de padrões de arquitetura escaláveis, como microsserviços e fragmentação de bancos de dados, complementa a importância de



algoritmos eficientes na construção de software capaz de lidar com o crescimento.

## 10. Conclusão

Este relatório explorou o conceito fundamental de complexidade de algoritmos em ciência da computação, abrangendo sua definição, os diferentes tipos de complexidade (tempo e espaço), a importância da notação Big O para descrever o comportamento assintótico dos algoritmos, e exemplos práticos de algoritmos com diversas complexidades. Demonstrou-se como a escolha de algoritmos e estruturas de dados afeta diretamente a eficiência e, crucialmente, a escalabilidade do software.

A análise da complexidade de algoritmos fornece uma ferramenta poderosa para os desenvolvedores de software e cientistas da computação avaliarem e compararem a eficiência de diferentes soluções para um determinado problema. Compreender a notação Big O permite prever como o desempenho de um algoritmo se degradará à medida que o tamanho da entrada aumenta, auxiliando na escolha do algoritmo mais adequado para as necessidades específicas de uma aplicação.

A decisão entre diferentes algoritmos e estruturas de dados muitas vezes envolve um equilíbrio entre complexidade de tempo e espaço, bem como outras considerações práticas. No entanto, para sistemas que precisam lidar com grandes volumes de dados ou um grande número de usuários, a escolha de algoritmos com menor complexidade é essencial para garantir a escalabilidade e manter um desempenho aceitável. Portanto, a consideração da complexidade de algoritmos deve ser uma parte integrante do processo de design e desenvolvimento de software.

## Referências citadas

1. Análise da Complexidade de Algoritmos: entenda! - Iugu, acessado em março 24, 2025, <https://www.iugu.com/blog/analise-complexidade-algoritmos>
2. Complexidade de Algoritmos - IME-USP, acessado em março 24, 2025, <https://www.ime.usp.br/~song/mac5710/slides/01complex.pdf>
3. www.inf.ufrgs.br, acessado em março 24, 2025, <https://www.inf.ufrgs.br/~prestres/Slides/aula1.pdf>
4. Notação Big O e guia de complexidade de tempo: Intuição e matemática | DataCamp, acessado em março 24, 2025, <https://www.datacamp.com/pt/tutorial/big-o-notation-time-complexity>
5. Entenda a complexidade algorítmica e notação Big O na ..., acessado em março 24, 2025, <https://www.escoladnc.com.br/blog/a-importancia-da-complexidade-algoritmica-e-notacao-big-o-na-programacao/>
6. O que é escalabilidade de software e serviços? | Lucidchart Blog, acessado em março 24, 2025, <https://www.lucidchart.com/blog/pt/o-que-e-escalabilidade-de-software-e-servicos>
7. Complexidade Quadrática  $O(N^2)$  | Wagner Abrantes | GoLang | DIO, acessado em março

- 24, 2025, <https://www.dio.me/articles/complexidade-quadratica-on2>
8. Complexidade temporal – Wikipédia, a enciclopédia livre, acessado em março 24, 2025, [https://pt.wikipedia.org/wiki/Complexidade\\_temporal](https://pt.wikipedia.org/wiki/Complexidade_temporal)
  9. Complexidade de tempo – Wikipédia, a enciclopédia livre, acessado em março 24, 2025, [https://pt.wikipedia.org/wiki/Complexidade\\_de\\_tempo](https://pt.wikipedia.org/wiki/Complexidade_de_tempo)
  10. Estruturas de dados: uma introdução | Alura, acessado em março 24, 2025, <https://www.alura.com.br/artigos/estruturas-de-dados-introducao>